当人工智能成为第一读者：从同行评审到贡献的确权与结算

When AI Becomes the First Reader: From Peer Review to Proof of Contribution

[待填]

2026 年 11 月 1 日

研究型工作论文初稿（Working Paper Draft）

摘要

学术评价长期围绕一个相对稳定的程序展开：研究者提交完整论文，同行阅读并判断其质量，期刊或会议作出发表决定，随后机构以论文及其发表场所分配声誉、职位与资源。生成式人工智能正在改变这一程序的前端。研究成果越来越容易先进入机器的检索、概括、筛选和预评价流程，再进入人类的注意范围。本文把这种在学术信息接触顺序和可见性分配上的变化称为“人工智能成为第一读者”。这一命题并不意味着所有论文都先由人工智能阅读，也不意味着机器已经取代人类的实质判断；它指向一种值得测量的制度变化：越来越多的学术接触由机器中介。由此产生两种错位：其一，知识贡献实际发生在数据、方法、证据、验证与维护等组件上，信用却主要按整篇论文结算；其二，传统同行评审以有限的人类阅读能力为前提，而成果的发现与传播正受到机器通道影响。本文提出将学术信用理解为原创性、证据质量、验证、维护和下游使用构成的五维向量，以可追溯的知识组件为记账单位，使同行评审、独立复核、持续维护及有证据的复用共同参与贡献的确权与结算。这里的“贡献证明”不是一种自动评分工具，也不是以机器取代审稿人，而是将可核查的贡献事实与规范性的学术判断分开记录。本文最后提出可证伪的经验命题及后续系统设计与评价路径。核心结论是：学术评价需要升级同行评审，而不是废除同行评审。

关键词：学术信用；人工智能；第一读者；同行评审；知识组件；贡献记账

1　第一读者之变

一篇论文的社会生命，过去通常从一个人开始：编辑、评审人、导师或偶然遇见它的同行阅读其题名、摘要和正文，决定是否继续注意、引用、推荐或质疑。今日的路径已经不再如此单一。检索系统先决定论文能否被找到，摘要和推荐系统先为论文提供一个可消费的表述，辅助评审工具还可能在人类决定之前形成评价线索。这里的“读”不是理解主体的拟人化说法，而是指机器对文献内容进行解析、压缩、关联、排序和输出判断的操作。所谓“第一读者”（first reader），因此是一种关于信息进入评价系统的先后顺序与中介权力的分析概念，而不是断言机器具备与学者相同的理解能力。

这一变化已有局部、可核查的迹象。Liang 等对四个机器学习与自然语言处理会议的评审文本进行统计估计，报告其中约 6.5%–16.9% 的评审文本可能经过大型语言模型实质性修改；这是一种语料总体估计，既不是逐个审稿人的行为确认，也不能直接推出评审决定已由机器作出 [4]。与此同时，科研写作本身也出现规模性的语言模型参与迹象 [5]。两项研究分别触及论文生产端和判断端，显示人类独占文本初步处理的前提已被动摇，却仍不足以证明所有学科、所有成果均经过机器的首次阅读。

制度反应同样说明这种变化尚未形成共识。美国国立卫生研究院（NIH）于 2023 年明确禁止其同行评审人在分析资助申请和撰写评审意见时使用生成式人工智能，主要理由是保密与评审完整性 [10]。2025 年，NIH 进一步规定，实质上由人工智能开发的资助申请或其中部分内容不能被视作申请人的原创构想 [11]。一边是工具不断进入研究与评审流程，一边是特定机构对使用边界的收紧。禁令不能证明技术无用，采用也不能证明其可靠；二者共同表明，机器已经成为学术制度必须明确对待的参与因素。

需要区分两个层次。经验层次的问题是：哪些学科、哪些环节、以多大比例把机器处理置于人的直接阅读之前？现有证据尚不足以回答普遍性的比例问题。制度层次的问题是：如果研究者、评审者和读者日益通过机器摘要与排序接触成果，那么机器所呈现的内容就会影响什么工作获得注意、什么证据被看见、什么贡献被忽略。这种影响不必等到机器具有最终裁决权才发生。一个方法可能被反复复用，却从未以独立论文形式发表；一个数据集可能是许多成果的前提，却在自动生成的摘要里消失。谁先决定信息的可见性，谁就部分塑造了随后能被评价的对象。

不能因此把“第一读者”与“第一裁决者”混为一谈。机器可以先筛选，却不应自动取得学术价值的终局判断权；人在使用机器推荐时仍承担审查义务。真正的新问题不只是如何管理人工智能写论文或帮人审论文，而是：当生产、传播和初步评价由多种人机流程交织完成，学术共同体应依据什么证据确认贡献、把信用记到哪里、又由谁完成结算?

2 结算机制的失灵

同行评审（peer review）首先是一种质量控制和公共判断程序：由具有相关知识的人检查研究问题、方法、证据与论断是否相称。它的价值在于背景理解、批判性解释以及专业共同体对判断负责。本文所说的“信用结算”（credit settlement），则是一个不同的制度环节：将研究劳动和成果转换为能够影响声誉、资源与职业评价的可记录认可。严格说来，同行评审从来不是全部信用的唯一来源；引用、奖项、软件使用、数据共享和同行声誉早已存在。问题在于，在许多正式评价程序里，经过评审并发表的整篇论文及其发表场所仍被当作便于汇总、比较和分配资源的主导凭证。因此，“唯一结算机制”的说法应理解为对这种制度性主导地位的批评，而非对学术史的字面描述。

第一种错位是**粒度错位**。论文适于讲述一个有始有终的研究故事，却不等于贡献产生的最小单位。一个研究可包含原始数据、清洗规则、识别策略、代码实现、理论命题、负结果、复现实验和多年维护。它们可能由不同人完成，可靠程度也不同。按整篇论文给出单一的发表标签，会把这些差异压缩到一个共同信号。作者排序和贡献声明能够缓解归属不清，却难以回答某个数据版本是否仍可运行、某项验证是否独立、某段代码后来究竟被哪些研究使用。学术成果的表达单位与学术劳动的记账单位，在这里发生了混同。

压缩具有现实成本。数据维护通常缺少新颖论文所拥有的发表机会；复现失败可能帮助整个领域停止浪费资源，却未必得到与正向结果相当的承认；一个理论结论若依赖脆弱数据，整篇论文的发表状态也不会自动揭示其不同组件的证据强弱。相反，某篇论文即使主要结论后来受到质疑，其中的数据资源或工具仍可能独立具有价值。这意味着“论文可信”与“论文内部每一项贡献都可信、且由同一人完成”并不是同一个判断。

第二种错位是**通道错位**。传统评审组织围绕稀缺的专家时间建立，稿件等待、审稿、修改、录用，然后通过期刊和会议进入读者视野。这种慢通道依赖人能逐篇读懂并形成相对完整的判断。机器通道则可以在极短时间内处理大量摘要、元数据和全文片段，但其输出可能丢失条件、混淆主张与证据，并把原有排名偏差继续放大。机器的处理速度与学术判断的可问责性并不同步。若制度只记录终点的录用与否，却不记录此前哪些证据经过谁的检验、被哪些系统怎样转述，信用就难以沿真实的知识流动路径追溯。

现行制度的压力不仅来自机器。Van Noorden 对 2023 年撤稿数量的报道显示，撤稿规模已经达到令人警惕的水平，其中涉及出版环节的系统性问题 [8]。撤稿数量上升本身不能证明同行评审普遍无效，也可能反映核查能力改善；但它足以提醒我们，

发表决定并不等于永久有效的质量保证。论文工厂与不当署名交易则进一步揭示：当一篇论文成为高价值、可交易的职业凭证，参与者就有动机争夺“论文身份”，而非呈现可审核的具体贡献。这里的逻辑是激励风险，不是对所有作者的道德指控。

以人工智能检测器填补缺口同样有局限。Liang 等发现，多种检测工具会对非英语母语作者的英文文本产生显著偏误 [7]；Weber-Wulff 等比较检测工具后也强调其可靠性问题 [12]。Sadasivan 等从理论与实验角度讨论了可靠识别机器生成文本的困难 [13]。这些发现不能推出任何特定文本都不可检验，却足以反对把“看起来像 AI 写的”直接当作否认贡献或实施惩罚的证明。对研究而言，更有价值的问题是数据从何而来、方法是否实施、结果能否复核、责任由谁承担，而不是句子的表面风格。

必须明确对同行评审的反驳边界。专家评审也可以考察组件，开放同行评审可以保留长期记录，部分学科早有软件与数据评价传统；因此两种错位不是由同行评审的定义必然产生，而是由以整篇发表作为主导、近乎终局的信用代理变量这一制度实践放大。即使完全禁止 AI 进入审稿，组件贡献被压缩的问题仍然存在；即使全面自动化审稿，机器也不会自然解决作者归属和证据独立性。需要改变的是结算对象与凭证组织方式，而非简单更换裁决者。

3 从同行评审到贡献证明

本文提出将“贡献证明”（proof of contribution）理解为**贡献的确权与结算**：对某项知识工作具体做了什么、由谁做、依据什么可以核查、后来发生了什么，建立持续、可质疑的记录，并把这些记录纳入学术信用分配。这里的“证明”不是数学定理式的绝对证明，也不是区块链、代币或单一自动评分器的同义词。它是一套要求证据、可追溯性和责任主体的制度原则。其目的不是淘汰整篇论文，而是让论文从唯一的信用容器转变为能够引用多项独立贡献凭证的综合叙述。

首先，信用不宜默认压缩为一个分数。设一项可辨识的知识贡献为 c，用五维表述

$$\mathbf{C}(c) = (O_c, E_c, V_c, M_c, U_c),$$

其中 O 为原创性（origination），记录问题、概念、数据或方法的首创及其来源；E 为证据质量（evidence quality），记录材料是否充分、方法与结论是否匹配；V 为验证（verification），记录独立复核、重复实验、反例与争议；M 为维护（maintenance），记录勘误、版本更新、长期可用性；U 为下游使用（downstream use），记录他人对该组件有证据的采用、扩展或依赖。向量是评价维度的组织方式，不是本文已经测量出来

的指标。五个维度既不独立，也不天然等权：广泛复用不能补偿伪造证据，技术维护不能替代原创发现，负面的验证结果也可能构成重要贡献。因此，不预设求和公式、全学科通用权重或按引用次数自动分配信用。

其次，记账单位需要下降到“知识组件”（knowledge component）。组件是能够被标识、说明边界、追溯版本并接受相应检验的最小实用贡献对象，例如一份有来源说明的数据、一个明确输入输出的方法、一项可定位的实证结果、一套复现脚本或一份持续更新的检验报告。所谓“最小实用”，不是把工作拆成每行代码或每句话；过度拆分会制造无法治理的碎片与虚假精度。组件应当独立到足以清楚描述其责任、依赖和验证方式，又完整到能被同行理解和再使用。整篇论文仍可把这些组件连接为有解释力的论证。

一个可行的记录结构至少需要四类关系。归属关系说明提出者、实现者和复核者各自承担的工作，并允许多人共享而不强制虚构精确百分比；依赖关系指明一项结论基于哪些数据、方法与外部成果；证据关系附上版本化材料、实验条件、审查意见和可核查的结果；时间关系保存后续更正、失效、维护和复用。对于无法公开的敏感数据，可以提供受控核查路径或公开可核实的说明，而不能以“未上传全部数据”为由自动认定不存在贡献。记录必须允许异议和修订；确权既包括赋予信用，也包括发现错误后更正信用。

再次，结算渠道必须多元化。传统同行评审仍然是判断科学意义、推理质量及领域适切性的关键机制；独立复现为特定结论提供有范围限制的验证；数据与软件审核针对可用性和来源完整性；维护记录评价长期责任；经过核实的下游使用反映组件在其他研究中的作用。这些证据应并列呈现而非强行折合成同一排名。eLife 以公开评审意见和研究评价替代传统的单次录用／拒绝判定，提供了将“发表”和“评价”适度分离的制度实例；但这不等于其已经实现组件级信用结算。由此可见，多元渠道具有实践可想象性，而本文方案仍需要独立设计与检验。

讨论一个假设性情景：甲发布具有明确定义和版本的数据组件，乙提出在其上运行的方法，丙复现出部分结果，丁发现边界条件并维护纠错记录。传统论文系统可能把这些劳动分别折入数量不等、声望不等的论文；组件记账则能记录数据原创、方法原创、验证与维护等不同角色。在这一方案中，丙的负面复现不必抹去甲的数据贡献，甲的数据被反复调用也不能直接证明乙的方法可靠。这个例子用于说明概念上的可区分性，不是已经运行的系统或取得的实证效果。

方案面临至少四项硬约束。第一，验证不能自动等于真理：可复现的错误仍是错误，复现失败也可能源于环境或测量差异，因此必须记录验证对象、条件和不确定性。

第二，下游使用容易被操纵：自引、互引与自动调用不能直接算作独立影响，应保留证据来源与利益关系。第三，细粒度记账会增加行政负担：若需要研究者无限填写表格，制度将损害研究本身，故应优先复用现有标识与工作流。第四，机器生成的总结可能掩盖少数人的关键劳动：需要允许当事人质疑归属与算法可见性，并提供人类申诉和更正路径。这些限制不应藏在系统实现之后，而应成为评价方案是否成立的先决条件。

还应防止以“多维信用”为名引入更隐蔽的单一权力。若机构最终仍把五维向量换算为一个不透明总分，原有的发表场所崇拜只会转化为指标崇拜。不同学科对原创性、复核成本和维护义务的理解不同，信用记录因此需要统一的事实层与可讨论的规范层：前者追踪谁完成了什么及有哪些证据，后者由合法的学术共同体结合任务作出价值判断。自动化宜用于搜集、关联和提示可核查证据，而不是隐藏判断依据。**这是一项对同行评审的升级，不是对同行评审的废除**。

4 研究议程

本文是一篇立场论文（position paper），其任务是提出可受批判的制度命题，而非宣称新制度已经有效。后续研究宜按三个相互衔接的阶段推进。第一阶段是本篇的概念论证，明确“第一读者”“贡献组件”“信用维度”和“结算渠道”的定义，确定何种现象足以反驳主张。第二阶段是系统研究（system paper）：建立有限范围的可运行原型，完成组件标识、依赖和归属记录、验证附着、版本更新与异议处理，并以真实研究流程演示能否生成可审核的贡献档案。第三阶段是设计科学评价（design-science evaluation）：比较新旧流程在归属准确性、审计成本、争议解决和可理解性上的表现，再提炼可迁移的设计原则。这一顺序与设计科学强调人工制品、评价和知识贡献的研究传统一致 [1, 2, 3]。

研究至少需要回答三个可检验命题。**现象命题**：在明确限定的学科和时间窗口中，经由 AI 介导的摘要、发现或预评价成为人类首次深入阅读之前重要的信息入口。可通过具备知情同意的研究者日志、检索行为与工作流程访谈测量；若机器中介比例很低或未影响文献选择，广泛的“第一读者”判断就应被收缩。**机制命题**：按篇评价比组件级记录更容易遗漏可核查的验证、维护及数据贡献。可以采用同一组研究成果的盲评对照，让评价者分别使用传统论文档案和结构化组件档案，考察归属差异与判断的一致性；若增益不存在或成本过高，机制主张就不成立。**方案命题**：在不降低专业判断质量的条件下，多元证据记录能够改善归属可追溯性和争议更正效率。应以预先规定的评价指标、不同学科样本和人工审核成本评估原型，而不能仅凭演示流畅或使

用者满意度宣布成功。

三个命题还须面对因果识别问题。采用 AI 工具的研究者和不采用者可能原本就具有不同的阅读能力与学术地位；组件记录提高可见性的同时，也可能仅仅奖励更擅长记录工作的团队。评价设计应记录这些混杂因素，并把“记录更完整”与“贡献分配更公正”分开测量。此外，参与者可能为了取得更高信用而改变行为，因此需要观察制度试行后的策略性调整，而不是只评估静态历史资料。

研究共同体还应保留价值判断上的分歧：一份长期维护的数据究竟应获得多少认可，一次有建设性的失败复现应如何进入职业评价，原创构想和集体基础设施应如何比较，无法仅靠技术接口回答。Messeri 与 Crockett 提醒，人工智能带来的产出效率可能与理解的幻觉并存 [9]。若新制度只是让论文、指标和自动摘要增长得更快，却未能使人更清楚地知道证据在哪里、贡献属于谁、哪些结论仍有争议，那么它并未解决本文提出的问题。

综上，人工智能成为“第一读者”应被视作一个需要继续测量的制度趋势，而不是已经证实的普遍事实；同行评审的困境来自按篇结算与传播通道变化之间的张力，而不是专家判断失去价值。本文主张将贡献的事实记录下沉到知识组件，把原创性、证据质量、验证、维护和下游使用分开呈现，再由包含同行评审在内的多种机制完成有责任的信用结算。未来制度是否优于现状，必须由可复核的系统和跨情境的评价来回答。需要改变的不是学术共同体坚持审查的原则，而是让审查结果能够准确指向实际发生的知识贡献。

参考文献

[1] Hevner, A. R., March, S. T., Park, J., & Ram, S. (2004). Design science in information systems research. *MIS Quarterly*, 28(1), 75–105.

[2] Peffers, K., Tuunanen, T., Rothenberger, M. A., & Chatterjee, S. (2007). A design science research methodology for information systems research. *Journal of Management Information Systems*, 24(3), 45–77.

[3] Gregor, S., & Hevner, A. R. (2013). Positioning and presenting design science research for maximum impact. *MIS Quarterly*, 37(2), 337–355.

[4] Liang, W., Izzo, Z., Zhang, Y., et al. (2024). Monitoring AI-modified content at scale: A case study on the impact of ChatGPT on AI conference peer reviews. In *Proc. ICML*.

arXiv:2403.07183.

[5] Liang, W., Zhang, Y., Wu, Z., et al. (2024). Mapping the increasing use of LLMs in scientific papers. arXiv:2404.01268.

[6] Latona, G. R., Ribeiro, M. H., Davidson, T. R., Veselovsky, V., & West, R. (2024). The AI review lottery: Widespread AI-assisted peer reviews boost paper scores and acceptance rates. arXiv:2405.02150.

[7] Liang, W., Yuksekgonul, M., Mao, Y., Wu, E., & Zou, J. (2023). GPT detectors are biased against non-native English writers. *Patterns*, 4(7), 100779.

[8] Van Noorden, R. (2023). More than 10,000 research papers were retracted in 2023—a new record. *Nature*, 624, 479–481.

[9] Messeri, L., & Crockett, M. J. (2024). Artificial intelligence and illusions of understanding in scientific research. *Nature*, 627, 49–58.

[10] National Institutes of Health. (2023). The use of generative artificial intelligence technologies is prohibited for the NIH peer review process. Notice NOT-OD-23-149.

[11] National Institutes of Health. (2025). Notice NOT-OD-25-132.

[12] Weber-Wulff, D., et al. (2023). Testing of detection tools for AI-generated text. *Int. J. Educational Integrity*, 19, 26.

[13] Sadasivan, V. S., Kumar, A., Balasubramanian, S., Wang, W., & Feizi, S. (2023). Can AI-generated text be reliably detected? arXiv:2303.03635.