当人工智能成为第一读者：从同行评审到贡献的确权与结算

When AI Becomes the First Reader: From Peer Review to Proof of Contribution

[待填]

2026 年 11 月 1 日

研究型工作论文第三轮修订稿（Working Paper Draft, Round 3）

摘要

学术评价长期围绕一个相对稳定的程序展开：研究者提交完整论文，同行阅读并判断其质量，期刊或会议作出发表决定，随后机构以论文及其发表场所分配声誉、职位与资源。生成式人工智能正在改变这一程序的前端。研究成果越来越容易先进入机器的检索、概括、筛选和预评价流程，再进入人类的注意范围。本文把这种在学术信息接触顺序和可见性分配上的变化称为“人工智能成为第一读者”。这一命题并不意味着所有论文都先由人工智能阅读，也不意味着机器已经取代人类的实质判断；它指向一种值得测量的制度变化：越来越多的学术接触由机器中介。由此产生两种错位：其一，知识贡献实际发生在数据、方法、证据、验证与维护等组件上，信用却主要按整篇论文结算；其二，传统同行评审以有限的人类阅读能力为前提，而成果的发现与传播正受到机器通道影响。本文提出将学术信用理解为原创性、证据质量、验证、维护和下游使用构成的五维向量，以可追溯的知识组件为记账单位，使同行评审、独立复核、持续维护及有证据的复用共同参与贡献的确权与结算。这里的“贡献证明”不是一种自动评分工具，也不是以机器取代审稿人，而是将可核查的贡献事实与规范性的学术判断分开记录。本文最后提出可证伪的经验命题及后续系统设计与评价路径。核心结论是：学术评价需要升级同行评审，而不是废除同行评审。

关键词：学术信用；人工智能；第一读者；同行评审；知识组件；贡献记账

1 第一读者之变

2025 年一项研究者调查显示，61% 的受访者使用人工智能工具来发现和概括学术论文，而不是直接在期刊平台阅读；《Nature Sensors》2026 年的社论引用了这一调查。该社论同时指出，Perplexity AI 在 2025 年日搜索量超过 3000 万次，并已与 Wiley 合作，通过其平台直接提供经过同行评审的内容 [14]。前者是受访者自述，后者是平台总搜索量，均不能直接衡量论文的首次 AI 阅读，却显示期刊之外的平台开始影响学术可见性。

论文的发现与评价不再只由期刊页面和人类阅读启动：检索、摘要、推荐和辅助评审系统正在决定哪些内容先进入视野。此处“读”指机器解析、压缩、关联、排序和输出判断，而非具有人类理解能力。**“第一读者”不是“每篇论文先被机器打开”，而是“AI 系统大规模中介了学术内容的人类首次接触（发现、摘要、排序、预评价）”**。“首次接触”指据以决定是否继续阅读、引用或评价的首次有效信息接触，而非简单下载；机器是否改变选择须另行测量。因此，工具使用量不等于首次阅读量。

这一变化已有局部、可核查的迹象。Liang 等对四个机器学习与自然语言处理会议的评审文本进行统计估计，报告其中约 6.5%–16.9% 的评审文本可能经过大型语言模型实质性修改；这是语料总体估计，并非逐人确认，也不表示机器已主导决策 [4]。与此同时，科研写作本身也出现规模性的语言模型参与迹象 [5]。两项研究分别触及论文生产端和判断端，显示人类独占文本初步处理的前提已被动摇，却仍不足以证明所有学科、所有成果均经过机器的首次阅读。

制度反应同样说明这种变化尚未形成共识。美国国立卫生研究院（NIH）于 2023 年明确禁止其同行评审人在分析资助申请和撰写评审意见时使用生成式人工智能，主要理由是保密与评审完整性 [10]。2025 年，NIH 进一步规定，实质上由人工智能开发的资助申请或其中部分内容不能被视作申请人的原创构想 [11]。Latona 等对 ICLR 2024 评审开展准实验与匹配分析：在识别出的同稿不同评分评审配对中，AI 辅助评审给出较高分数的比例为 53.4%；在接近录用阈值的匹配样本中，收到 AI 辅助评审的投稿录用率高出 4.9 个百分点 [6]。这些结果依赖检测器分类、匹配条件与所研究会议的制度环境，不能直接解释为 AI 造成录用率上升的普遍因果效应；但它们说明，机器介入评审不仅关涉措辞，也与可观察的评审结果相关。一边是工具不断进入研究与评审流程，一边是特定机构对使用边界的收紧。禁令与采用共同表明，制度须明确机器的参与边界。

经验层次需要测量 AI 在不同学科和任务中先于直接阅读介入的比例；现有证据无法回答其普遍程度。制度层次关注 AI 摘要、排序如何改变成果的可见性：方法与

数据可能被反复复用，却在整篇论文的摘要和排序中缺席。机器不必拥有最终裁决权，也能影响后续评价对象。

这一现象主张必须允许被证伪。加强它的证据，至少包括出版社或平台经过审计的 AI 优先访问路径、得到研究者知情同意的阅读与检索流程日志，以及把首次机器生成摘要和首次人工正文阅读区分开的行为测量。相反，如果代表性样本显示 AI 中介在首次接触中占比低、使用后并未改变选择，或研究者仍主要经由传统入口发现并阅读原文，则必须缩小“第一读者”的适用学科、任务和时期，乃至放弃其强版本。这一检验将在第四节转化为可观察的现象命题。

“第一读者”不等于“第一裁决者”：人类仍承担实质审查责任。核心问题是，当生产、传播和初评交织在人机流程中，学术信用应凭何种证据、按何种单位、由谁结算?

2 结算机制的失灵

需要先限定历史对象：本文批判的是二**战后以整篇期刊论文为信用凭证的主导制度实践**，尤其是以期刊发表及发表场所代理贡献质量的正式资源分配方式，而不是声称学术信用在历史上只有单一通道。前期刊时代的书信、学术社群与专著，及现代的预印本、会议、专利、软件和数据贡献，均表明研究认可一直具有多种渠道；不同学科中期刊论文的支配程度也并不相同。这里的历史划分是需要分领域检验的制度概括，不把“二战后”处理成全球统一且瞬时发生的断点。

同行评审（peer review）是专家审查问题、方法、证据与结论的质量控制程序；“信用结算”（credit settlement）则是将贡献转换为声誉、职位和资源认可的制度环节。引用、奖项及软件使用早已提供其他认可渠道，但正式评价往往把经过评审的整篇论文及发表场所作为便于汇总的主导凭证。“唯一结算机制”因此指其制度主导地位，而非字面上的历史唯一性。

第一种错位是**粒度错位**。论文适于讲述一个有始有终的研究故事，却不等于贡献产生的最小单位。一个研究可包含原始数据、清洗规则、识别策略、代码实现、理论命题、负结果、复现实验和多年维护。它们可能由不同人完成，可靠程度也不同。按整篇论文给出单一的发表标签，会把这些差异压缩到一个共同信号。作者排序和贡献声明能够缓解归属不清，却难以回答某个数据版本是否仍可运行、某项验证是否独立、某段代码后来究竟被哪些研究使用。学术成果的表达单位与学术劳动的记账单位，在这里发生了混同。

按篇结算会掩盖维护与负面复现的贡献：一篇论文的主要结论受质疑，其数据或

工具仍可有独立价值。“论文已发表”并不等于各组件都经独立验证，也不等于所有贡献由同一人完成。

第二种错位是**通道错位**。传统评审组织围绕稀缺的专家时间建立，稿件等待、审稿、修改、录用，然后通过期刊和会议进入读者视野。这种慢通道依赖人能逐篇读懂并形成相对完整的判断。机器通道则可以在极短时间内处理大量摘要、元数据和全文片段，但其输出可能丢失条件、混淆主张与证据，并把原有排名偏差继续放大。机器的处理速度与学术判断的可问责性并不同步。若制度只记录终点的录用与否，却不记录此前哪些证据经过谁的检验、被哪些系统怎样转述，信用就难以沿真实的知识流动路径追溯。

现行制度的压力不仅来自机器。Van Noorden 对 2023 年撤稿数量的报道显示，撤稿规模已经达到令人警惕的水平，其中涉及出版环节的系统性问题 [8]。撤稿数量上升本身不能证明同行评审普遍无效，也可能反映核查能力改善；但它足以提醒我们，发表决定并不等于永久有效的质量保证。论文工厂与不当署名交易则进一步揭示：当一篇论文成为高价值、可交易的职业凭证，参与者就有动机争夺“论文身份”，而非呈现可审核的具体贡献。这里的逻辑是激励风险，不是对所有作者的道德指控。

依靠文本检测器封堵 AI 也不能解决信用问题：Liang 等报告非英语母语作者面临显著误判，其他研究揭示检测工具可靠性及稳健性限制 [7, 12, 13]。因此不能从风格检测直接推定作者失信；制度应转向核查数据来源、方法执行、结果复核和责任归属。

多元结算是回归，而非凭空发明。专著、会议、专利、数据与软件已有各自认可传统；新制度要用可审计的基础设施重新组织这种多元性，而不是复归未经检验的旧秩序。

反驳边界必须清楚：专家评审可以考察组件，开放评审可留下长期记录，部分学科早有软件和数据评价。双重错位来自整篇发表凭证的主导地位，并非同行评审必然失败；禁用 AI 不消除粒度问题，自动审稿也不自动解决归属问题。

3　从同行评审到贡献证明

本文提出将“贡献证明”（proof of contribution）理解为**贡献的确权与结算**：对某项知识工作具体做了什么、由谁做、依据什么可以核查、后来发生了什么，建立持续、可质疑的记录，并把这些记录纳入学术信用分配。这里的“证明”不是数学定理式的绝对证明，也不是区块链、代币或单一自动评分器的同义词。它是一套要求证据、可追溯性和责任主体的制度原则。其目的不是淘汰整篇论文，而是让论文从唯一的信用容

器转变为能够引用多项独立贡献凭证的综合叙述。

首先，信用不宜默认压缩为一个分数。设一项可辨识的知识贡献为 c，用五维表述

$$\mathbf{C}(c) = (O_c, E_c, V_c, M_c, U_c),$$

其中 O 为原创性（origination），E 为证据质量（evidence quality），V 为验证（verification），M 为维护（maintenance），U 为下游使用（downstream use）。五维向量是概念模型而非已经测量的得分，维度既不独立，也不天然等权；广泛复用不能补偿伪造证据，复现失败也可能有价值。表1把候选指标、测量缺陷与决策用途明确分开。所列数据源类型已经存在，但不代表本文掌握跨学科完整数据库。

Table 1: 五维贡献的可观测性、构念效度与制度适用性（候选设计，非实证结果）

维度	可观测性：候选数据源	构念效度：主要偏差	制度适用性：决策主体与用途
O 原创性	结构化新颖性声明；时间戳版本；后验“首创”归因	后验归因有赢者叙事；时间戳能证“先”，不能证“重要”	高校聘用、终身教职；奖项首创性审查
E 证据质量	数据/代码可用性徽章；方法—结论匹配的具名评审	可用不等于正确；徽章可能形式化；评审有主观性	期刊/会议录用；资助项目评审
V 验证	复现徽章；公开评审；可定位反例和复核报告	可复现的错误仍是错误；阴性复现难发表使观测偏斜	资助续资/结题；领域共识形成
M 维护	版本更新、勘误响应、长期可用性检查	更新频率不等于维护质量；跨学科维护价值难比	基础设施与长期项目资助者；数据仓储运营方
U 下游使用	文献引用、代码依赖、数据引用；剔除自引、互引、自动调用	引用有支持、批评、装饰等动机；引用文化有学科差异	高校影响力评价；政策与社会影响评估

可观测性是入场券，构念效度是诚实性，制度适用性是用途。同一维度可能容易记录却难以有效解释（如 U），也可能具有明确维护要求却缺乏通用制度采用（如 M）。不同决策需要不同的“维度—效度要求”组合；一个预设总分会抹掉这些差别，在某些决策中误用指标。因此，不预设求和公式或跨学科统一权重，是有明确测量学理由的制度设计原则。

其次，记账单位需要下降到“知识组件”（knowledge component）。组件是能够被标识、说明边界、追溯版本并接受相应检验的最小实用贡献对象，例如一份有来源说明的数据、一个明确输入输出的方法、一项可定位的实证结果、一套复现脚本或一份持续更新的检验报告。所谓“最小实用”，不是把工作拆成每行代码或每句话；过度拆分会制造无法治理的碎片与虚假精度。组件应当独立到足以清楚描述其责任、依赖和验证方式，又完整到能被同行理解和再使用。整篇论文仍可把这些组件连接为有解释力的论证。

一个可行的记录结构至少需要四类关系。归属关系说明提出者、实现者和复核者

各自承担的工作，并允许多人共享而不强制虚构精确百分比；依赖关系指明一项结论基于哪些数据、方法与外部成果；证据关系附上版本化材料、实验条件、审查意见和可核查的结果；时间关系保存后续更正、失效、维护和复用。对于无法公开的敏感数据，可以提供受控核查路径或公开可核实的说明，而不能以“未上传全部数据”为由自动认定不存在贡献。记录必须允许异议和修订；确权既包括赋予信用，也包括发现错误后更正信用。

再次，结算渠道必须多元化。传统同行评审仍然是判断科学意义、推理质量及领域适切性的关键机制；独立复现为特定结论提供有范围限制的验证；数据与软件审核针对可用性和来源完整性；维护记录评价长期责任；经过核实的下游使用反映组件在其他研究中的作用。这些证据应并列呈现而非强行折合成同一排名。eLife 以公开评审意见和研究评价替代传统的单次录用／拒绝判定，提供了将“发表”和“评价”适度分离的制度实例；但这不等于其已经实现组件级信用结算。由此可见，多元渠道具有实践可想象性，而本文方案仍需要独立设计与检验。

还需要把记录事实转换为实际制度决定，建立**“记录 → 采用 → 分配”**的责任链条。第一环由可互操作的开放基础设施保存标识、归属、依赖、证据和时间信息，维护可追溯的更改历史；开放指记录规范和可审计接口，而非要求敏感原始数据全面公开。第二环由具有具体责任的多元主体——领域同行、独立复核者、数据与软件审核者及受影响的贡献者——核查相应证据、标注适用范围并允许异议。第三环才是信用的制度结算：高校在聘任与晋升档案中明确披露各维贡献和审核理由，资助机构在拨款与续资中记录采用何种证据，期刊与会议在论文评价中呈现组件的验证和维护状态。三者可以据任务设置不同判断标准，却不能把无证据的机器总分伪装为事实。记录者不应同时垄断验证与最终资源分配，从而保留可问责的权力分离。

概念演示（非实证结果）：甲提供版本化数据，乙在其上提出方法，丙复现失败，丁记录适用边界并维护勘误。组件级记账可分别记录数据原创、方法原创、验证与维护；**丙的负面复现不必抹去甲的数据贡献**，甲的数据被复用也不能证明乙的方法可靠。

方案面临至少四项硬约束。第一，验证不能自动等于真理：可复现的错误仍是错误，复现失败也可能源于环境或测量差异，因此必须记录验证对象、条件和不确定性。第二，下游使用容易被操纵：自引、互引与自动调用不能直接算作独立影响，应保留证据来源与利益关系。第三，细粒度记账会增加行政负担：若需要研究者无限填写表格，制度将损害研究本身，故应优先复用现有标识与工作流。第四，机器生成的总结可能掩盖少数人的关键劳动：需要允许当事人质疑归属与算法可见性，并提供人类申诉和更正路径。这些限制不应藏在系统实现之后，而应成为评价方案是否成立的先决条件。

为使激励相容，系统需要明确哪些行为可观察、哪些不能据以给分以及如何处理争议。可观察行为包括可核验的版本提交、带来源的复现实验、外部代码或数据依赖、勘误响应时点，以及经申报的利益关系；未经验证的下载量、机器人访问量、互惠引用网络和批量生成的表面复核意见，不应自动增加信用。对于疑似刷分，先记录可复核的异常模式和证据，再由独立人员结合学科情境判定；不能以统计异常本身直接认定学术不端。受到影响的贡献者应拥有查看依据、提出反证、申请人工复核和保留纠正历史的途径，严重争议可由与初审相隔离的主体复议。这样的规则同样存在博弈和规避空间，因此须在第四节检验误报、漏报、审核工作量与各类参与者的策略性响应。

还应防止以“多维信用”为名引入更隐蔽的单一权力。若机构最终仍把五维向量换算为一个不透明总分，原有的发表场所崇拜只会转化为指标崇拜。不同学科对原创性、复核成本和维护义务的理解不同，信用记录因此需要统一的事实层与可讨论的规范层：前者追踪谁完成了什么及有哪些证据，后者由合法的学术共同体结合任务作出价值判断。自动化宜用于搜集、关联和提示可核查证据，而不是隐藏判断依据。**这是一项对同行评审的升级，不是对同行评审的废除**。

4 研究议程

本文是一篇立场论文（position paper），其任务是提出可受批判的制度命题，而非宣称新制度已经有效。后续研究宜按三个相互衔接的阶段推进。第一阶段是本篇的概念论证，明确“第一读者”“贡献组件”“信用维度”和“结算渠道”的定义，确定何种现象足以反驳主张。第二阶段是系统研究（system paper）：建立有限范围的可运行原型，完成组件标识、依赖和归属记录、验证附着、版本更新与异议处理，并以真实研究流程演示能否生成可审核的贡献档案。第三阶段是设计科学评价（design-science evaluation）：比较新旧流程在归属准确性、审计成本、争议解决和可理解性上的表现，再提炼可迁移的设计原则。这一顺序与设计科学强调人工制品、评价和知识贡献的研究传统一致 [1, 2, 3]。

研究至少需要回答三个可检验命题。**现象命题**：在明确限定的学科和时间窗口中，经由 AI 介导的摘要、发现或预评价成为人类首次深入阅读之前重要的信息入口。可联合出版社与检索平台的汇总访问数据、经知情同意的研究者工作流程日志，以及区分首次 AI 摘要、首次期刊页面浏览、首次正文阅读的检索行为测量；预注册“首次接触”的事件定义、采样框架与 AI 中介占比，并评估这些入口对文献选择的关联；若机器中介比例很低或未影响文献选择，广泛的“第一读者”判断就应被收缩。**机制命题**：按篇评价比组件级记录更容易遗漏可核查的验证、维护及数据贡献。可以采用

同一组研究成果的盲评对照，让评价者分别使用传统论文档案和结构化组件档案，考察归属差异与判断的一致性；若增益不存在或成本过高，机制主张就不成立。**方案命题**：在不降低专业判断质量的条件下，多元证据记录能够改善归属可追溯性和争议更正效率。应以预先规定的评价指标、不同学科样本和人工审核成本评估原型，而不能仅凭演示流畅或使用者满意度宣布成功。

三个命题还须面对因果识别问题。采用 AI 工具的研究者和不采用者可能原本就具有不同的阅读能力与学术地位；组件记录提高可见性的同时，也可能仅仅奖励更擅长记录工作的团队。评价设计应记录这些混杂因素，并把“记录更完整”与“贡献分配更公正”分开测量。此外，参与者可能为了取得更高信用而改变行为，因此需要观察制度试行后的策略性调整，而不是只评估静态历史资料。

维护数据、失败复现与原创构想应如何比较，需要学术共同体给出可问责的规范判断，而非技术接口直接决定。Messeri 与 Crockett 指出，AI 带来的产出效率可能伴随理解的幻觉 [9]；若制度只提高论文和指标产量，却不揭示证据、归属与争议，就未解决信用问题。

人工智能成为“第一读者”是待测量的制度趋势，非已经证实的普遍事实；按篇结算与传播通道变化构成张力，并非专家判断失去价值。以知识组件记录五维贡献，由包含同行评审在内的多元机制完成可质疑的信用结算，仍须经过可复核原型和跨情境评价。**这是一项升级，不是废除同行评审**。

参考文献

[1] Hevner, A. R., March, S. T., Park, J., & Ram, S. (2004). Design science in information systems research. *MIS Quarterly*, 28(1), 75–105.

[2] Peffers, K., Tuunanen, T., Rothenberger, M. A., & Chatterjee, S. (2007). A design science research methodology for information systems research. *Journal of Management Information Systems*, 24(3), 45–77.

[3] Gregor, S., & Hevner, A. R. (2013). Positioning and presenting design science research for maximum impact. *MIS Quarterly*, 37(2), 337–355.

[4] Liang, W., Izzo, Z., Zhang, Y., et al. (2024). Monitoring AI-modified content at scale: A case study on the impact of ChatGPT on AI conference peer reviews. In *Proc. ICML*. arXiv:2403.07183.

[5] Liang, W., Zhang, Y., Wu, Z., et al. (2024). Mapping the increasing use of LLMs in scientific papers. arXiv:2404.01268.

[6] Latona, G. R., Ribeiro, M. H., Davidson, T. R., Veselovsky, V., & West, R. (2024). The AI review lottery: Widespread AI-assisted peer reviews boost paper scores and acceptance rates. arXiv:2405.02150.

[7] Liang, W., Yuksekgonul, M., Mao, Y., Wu, E., & Zou, J. (2023). GPT detectors are biased against non-native English writers. *Patterns*, 4(7), 100779.

[8] Van Noorden, R. (2023). More than 10,000 research papers were retracted in 2023—a new record. *Nature*, 624, 479–481.

[9] Messeri, L., & Crockett, M. J. (2024). Artificial intelligence and illusions of understanding in scientific research. *Nature*, 627, 49–58.

[10] National Institutes of Health. (2023). The use of generative artificial intelligence technologies is prohibited for the NIH peer review process. Notice NOT-OD-23-149.

[11] National Institutes of Health. (2025). Notice NOT-OD-25-132.

[12] Weber-Wulff, D., et al. (2023). Testing of detection tools for AI-generated text. *Int. J. Educational Integrity*, 19, 26.

[13] Sadasivan, V. S., Kumar, A., Balasubramanian, S., Wang, W., & Feizi, S. (2023). Can AI-generated text be reliably detected? arXiv:2303.03635.

[14] Shaping the AI systems that speak for science. (2026). Editorial. *Nature Sensors*, 1, 559–560. https://doi.org/10.1038/s44460-026-00109-0.